Table of Contents

- 1分类变量预处理
 - 1.1 分类变量的缺失值和异常值处理
 - 1.1.1 分类变量的缺失值处理
 - 1.1.2 分类变量的异常值处理
 - 1.2 分类变量取值个数处理
- 2数值变量预处理
 - 2.1 数值变量的缺失值和异常值处理
 - 2.1.1 数值变量的缺失值处理
 - 2.1.2 数值变量的异常值处理
 - 2.2 数值属性预处理

```
In [1]: import pandas as pd
        import matplotlib.pyplot as plt
        from sklearn.cluster import KMeans
        from sklearn import metrics
        plt.rcParams['font.family']=['Songti SC']
        plt.rcParams['axes.unicode minus'] = False
        # pd.set option('precision', 5) #设置精度
        pd.set option('display.float format', lambda x: '%.5f' % x) #为了直观
        的显示数字, 不采用科学计数法
        pd.options.display.max rows = 200 #最多显示200行
In [2]: df = pd.read_csv("../data/Credit.csv", dtype = {"Label":'category',
        'GENDER': 'category', 'MARITAL STATUS': 'category', "LOANTYPE": "categ
        ory", "PAYMENT_TYPE":"category", 'ID':'category','AGE':'int'} )
        df.info()
        <class 'pandas.core.frame.DataFrame'>
        RangeIndex: 1412 entries, 0 to 1411
        Data columns (total 12 columns):
        ID
                                       1412 non-null category
        Label
                                       1412 non-null category
                                       1412 non-null int64
        AGE
        GENDER
                                       1412 non-null category
        MARITAL STATUS
                                       1412 non-null category
        MONTHLY INCOME WHITHOUT TAX
                                       1402 non-null float64
        LOANTYPE
                                       1412 non-null category
        GAGE TOTLE PRICE
                                       1412 non-null float64
                                       1412 non-null float64
        APPLY AMOUNT
        APPLY TERM TIME
                                       1412 non-null int64
        APPLY INTEREST RATE
                                       1412 non-null float64
        PAYMENT TYPE
                                       1412 non-null category
        dtypes: category(6), float64(4), int64(2)
        memory usage: 127.3 KB
```

1 分类变量预处理

```
df.select_dtypes(include=['category']).describe()
Out[3]:
                  ID Label GENDER MARITAL_STATUS LOANTYPE
                                                                             PAYM
          count 1412
                     1412
                             1412
                                            1412
                                                      1412
         unique 1412
                        2
                                               4
                 999
                        0
                                                  Frist-Hand Average_Capital_Plus_Interest_
            top
                              Male
                                          Married
           freq
                  1
                      762
                              782
                                             751
                                                      1117
        df.GENDER.value counts(normalize=True)
In [4]:
Out[4]: Male
                  0.55382
         Female
                  0.44618
        Name: GENDER, dtype: float64
In [6]: df.MARITAL STATUS.value counts(normalize=True)
Out[6]: Married
                   0.53187
         Single
                   0.35127
         Unknown
                   0.10269
         Divorce
                   0.01416
        Name: MARITAL STATUS, dtype: float64
In [5]: | df.LOANTYPE.value counts(normalize=True)
Out[5]: Frist-Hand
                        0.79108
         Second-Hand
                        0.20892
        Name: LOANTYPE, dtype: float64
In [7]: df.PAYMENT TYPE.value counts(normalize=True)
Out[7]: Average Capital Plus Interest Repayment
                                                      0.79320
        Matching The Principal Repayment
                                                      0.20680
        Name: PAYMENT TYPE, dtype: float64
```

1.1 分类变量的缺失值和异常值处理

- GENDER: 性别, 2类, 男、女
- MARITAL_STATUS: 婚姻状态, 4类, 已婚、单身、离婚、未知
- LOANTYPE: 贷款类型, 2类, 一手、二手
- PAYMENT_TYPE: 还款方式,2类,带利息、先还本金 ### 1.1.1 分类变量的缺失值处理 数据集中只有4个分类属性,且只有MARITAL_STATUS中有缺失值Unknown,占比10.269%,我们不删除该属性,将Unknown单独作为一类。

1.1.2 分类变量的异常值处理

没有异常值

1.2 分类变量取值个数处理

目的: 使得每个分类属性的取值都不超过5个

- 1. 检查删除
- 所有分类属性不存在某个取值占了90%以上, 所以没因此删除属性
- 所有分类属性不存在缺失值或者异常值占了50%以上, 所以没因此删除属性
- 分类属性只有2种取值,且这两种取值的odds又相等,则对违约分类无区分作用,所以要删除这种属性。下面来检查这种情况,性别、贷款类型、还款类型都是只有2种取值,经过检查,发现两个取值的odds都不相等,所以不用删除。

```
In [8]: #输入一个2值属性,判断要不要根据odds值删除它

def check_delete_odds_equal(df,feature):
    print(f"对于属性{feature}: ")
    for i in df[feature].value_counts().index:
        print(f"取值 {i} 的odds = {value_odds(df,feature,i)}")
    print("odds相等,需要删除属性" if (df[feature].value_counts().inde
    x[0] == df[feature].value_counts().index[1]) else "odds不等,不用删除
属性")
    print("\n")
```

```
In [9]: #输入一个属性的一个取值,可以得到该值对应的odds,我认为1是违约

def value_odds(df,feature,value):
    p = (df.loc[(df[feature] == value) & (df['Label'] == "1")].shap
e[0]) / df.shape[0] #p: bad ratio
    odds = p/(1-p)
    return odds
```

```
In [10]: bin_feature_list = ["GENDER","LOANTYPE","PAYMENT_TYPE"]
for i in bin_feature_list:
    check_delete_odds_equal(df,i)
```

对于属性GENDER:

取值 Male 的odds = 0.3183940242763772 取值 Female 的odds = 0.28014505893019037 odds不等,不用删除属性

对于属性LOANTYPE:

取值 Frist-Hand 的odds = 0.5533553355335534 取值 Second-Hand 的odds = 0.11620553359683795 odds不等,不用删除属性

对于属性PAYMENT TYPE:

取值 Average_Capital_Plus_Interest_Repayment 的odds = 0.55849889624 72406

取值 Matching_The_Principal_Repayment 的odds = 0.11356466876971609 odds不等,不用删除属性

1. 检查合并

• 分类属性中某个取值占比小于5%时,要与odds相近的取值合并成一类,直至每个取值占比大于5%。数据集里只有婚姻状态的Divorce取值低于5%,所以接下来找出Married、Single、Unknown这三个取值中与Divorce的odds最近的那个。下面的结果表示Unknown与Divorce的odds最接近,所以将二者并成一类,新类Unknown_Divorce的占比超过了5%,故停止合并。

```
In [11]:

def check_merge_odds_nearest(df,feature,value):
    opt = value_odds(df,feature,value)
    print(f"待合并值 {value} 的odds = {opt}")
    for i in df[feature].value_counts().index:
        if i == value:
            continue
            optt = value_odds(df,feature,i)
            print(f"取值 {i} 的odds = {optt}, 距离是{abs(optt-opt)}")
```

```
In [12]: check_merge_odds_nearest(df,"MARITAL_STATUS","Divorce")
```

待合并值 Divorce 的odds = 0.009292351679771264 取值 Married 的odds = 0.3208606173994388, 距离是0.3115682657196675 取值 Single 的odds = 0.18955349620893008, 距离是0.1802611445291588 取值 Unknown 的odds = 0.05137751303052867, 距离是0.04208516135075740

```
In [13]: df["MARITAL_STATUS"] = df["MARITAL_STATUS"].apply(lambda x: "Unknow
n_Divorce" if (x == "Unknown" or x == "Divorce") else x)
```

 继续检查合并,若属性中取值个数大于2,且其中某两个取值的odds相等,则需要将相等odds的取值 归为一类。

我们这里就只有属性婚姻状态取值个数大于2,那么就检查它的三个取值的odds有没有相等的情况,有就进行合并。从下面的输出结果可看出没有取值的odds相等,所以不合并。

最后、把所有字符串取值都变成数字形式方便输入模型

2数值变量预处理

In [18]: df.describe()

Out[18]:

	AGE	GENDER	MARITAL_STATUS	MONTHLY_INCOME_WHITHOUT_TAX	LO
count	1412.00000	1412.00000	1412.00000	1402.00000	141
mean	33.66643	0.55382	1.18059	730195.95822	
std	7.17158	0.49727	0.92257	22385106.02736	
min	18.00000	0.00000	0.00000	0.00000	
25%	28.00000	0.00000	0.00000	6000.00000	
50%	33.00000	1.00000	2.00000	8500.00000	
75%	38.00000	1.00000	2.00000	15000.00000	
max	67.00000	1.00000	2.00000	833333333.30000	

2.1 数值变量的缺失值和异常值处理

• AGE: 年龄

● MONTHLY_INCOME_WHITHOUT_TAX: 税前月收入,单位元

• GAGE_TOTLE_PRICE: 抵押品的总价值,单位元

• APPLY_AMOUNT: 申请的贷款金额, 单位元

• APPLY_TERM_TIME: 申请的还款时长,单位月

• APPLY_INTEREST_RATE: 贷款利率, 百分数

2.1.1 数值变量的缺失值处理

数据集中有6个数值变量,其中只有MONTHLY_INCOME_WHITHOUT_TAX统计出的数目比总样本个数少,说明有缺失值,我们进行查看,发现缺失值占0.7%,于是我们决定将缺失值单独归类为-1,并最终要将该属性进行离散化

```
In [17]: df.MONTHLY_INCOME_WHITHOUT_TAX.isna().value_counts(normalize=True)
Out[17]: False    0.99292
    True    0.00708
    Name: MONTHLY_INCOME_WHITHOUT_TAX, dtype: float64
```

```
In [19]: df.MONTHLY_INCOME_WHITHOUT_TAX.fillna(-1,inplace=True)
```

2.1.2 数值变量的异常值处理

异常的定义需要结合专业知识和常识,我们觉得每个客户的GAGE_TOTLE_PRICE都应该大于APPLY_AMOUNT,如果不是,说明其中登记有误。 下面进行检查,发现所有客户都符合抵押价值大于贷款值,故认为GAGE_TOTLE_PRICE和APPLY_AMOUNT都无误。

```
In [20]: df[df.GAGE_TOTLE_PRICE > df.APPLY_AMOUNT].shape[0]
```

Out[20]: 1412

年龄和贷款时间长度、利率也都正常,最大值和最小值都符合常识。

18178.00000

1

税前月收入,除了1.2.1中已经提到有缺失值,我们还发现最大值上亿,最小值为0。最小值0我们暂时理解为收集数据时该客户没有月收入,但是最大值我们认为是异常的,要进行观察。

我们发现top 25%的客户税前月收入超过15000,所以我们先观察税前月收入超过15000的客户,有多少异 常的。

我们发现异常的主要是月收入超过1000000的,如5833333.33300、12500000.00000、8333333.33300、28129588.00000、8333333333333000、83789551.00000、6666666.66700、5000000.00000。我们认为要结合其抵押价值和贷款金额来综合查看该数据是否异常。

```
df[df.MONTHLY INCOME WHITHOUT TAX>15000].MONTHLY_INCOME_WHITHOUT_TA
In [22]:
          X.value counts()
                               57
Out[22]: 20000.00000
          25000.00000
                               28
          18000.00000
                               23
          30000.00000
                               21
          50000.00000
                               19
          16000.00000
                               14
          35000.00000
                               10
          40000.00000
                                8
          60000.00000
                                8
          19000.00000
                                7
                                7
          28000.00000
          150000.00000
                                6
          21000.00000
                                6
          80000.00000
                                6
          100000.00000
                                5
          26000.00000
                                5
          22000.00000
                                5
          27000.00000
                                4
          17000.00000
                                4
          45000.00000
                                4
          23000.00000
                                4
          70000.00000
                                3
          36000.00000
                                3
          200000.00000
                                2
                                2
          1000000.00000
          33000.00000
                                2
                                2
          24000.00000
          25500.00000
                                2
          5833333.33300
                                2
          12500000.00000
                                2
          18800.00000
                                2
                                2
          300000.00000
          29000.00000
                                2
          44000.00000
                                2
          24400.00000
                                1
          116000.00000
                                1
          8333333.33300
                                1
```

```
15600.00000
                     1
126000.00000
                     1
21680.00000
                     1
65000.00000
                     1
22500.00000
                     1
58000.00000
                     1
66666.66667
                     1
16500.00000
                     1
208333.33330
                     1
28129588.00000
                     1
107000.00000
                      1
110000.00000
                     1
833333333.30000
                     1
23333.33333
                     1
83789551.00000
                     1
27700.00000
                     1
41600.00000
                     1
6666666.66700
                     1
34500.00000
                     1
15500.00000
                     1
27500.00000
                     1
86000.00000
                     1
38000.00000
                     1
17800.00000
                     1
68888.00000
                     1
5000000.00000
                     1
23800.00000
                     1
43000.00000
                     1
16666.66667
                     1
68000.00000
```

Name: MONTHLY INCOME WHITHOUT TAX, dtype: int64

如下,我们发现很多月入"千万"、"百万"级别的客户,抵押品价值只有几十万,贷款也是几十万甚至几万,与"身家"不符,所以我们认为这些客户的月收入填写异常。 如果不删除这部分客户,那就另存为一类-2。

```
In [21]: df[df.MONTHLY_INCOME_WHITHOUT_TAX >= 1000000]
```

Out[21]:

	ID	Label	AGE	GENDER	MARITAL_STATUS	MONTHLY_INCOME_WHITHOUT_TAX
36	37	0	34	1	0	28129588.00000
72	73	1	39	1	2	5000000.00000
86	87	0	43	1	2	12500000.00000
527	528	0	34	1	2	5833333.33300
733	734	0	26	0	0	83789551.00000
765	766	0	27	1	2	6666666.66700
1114	1115	0	41	0	0	8333333.33300
1147	1148	1	43	1	2	1000000.00000
1148	1149	1	43	1	2	1000000.00000
1233	1234	0	41	1	1	833333333.30000
1241	1242	1	36	0	1	12500000.00000
1274	1275	0	25	1	0	5833333.33300

```
In [23]: df["MONTHLY_INCOME_WHITHOUT_TAX"] = df["MONTHLY_INCOME_WHITHOUT_TAX"]
"].apply(lambda x: -2 if x >= 1000000 else x)
```

2.2 数值属性预处理

目的:数值属性离散化,离散化后取值不超过5个

```
In [24]: def find best k(feature, max k):
             print(f"找 {feature} 最合适的k值: ")
             \max score = 0
             best k = 0
             for i in range(2,max k+1):
                 score = k score(feature,i)
                 print(f"k = {i}时, score = {score}")
                 if score > max score:
                     max score = score
                     best k = i
             print(f"最终找到的最佳k = {best k}, 对应的max score = {max score}\n
         ")
             return best k
         def k score(feature,k):
             data = df[feature].copy()
             X = data.values.reshape((len(data), 1))
             kmodel = KMeans(n_clusters = k, random_state=0, n_jobs = -1)
             y pred = kmodel.fit predict(X)
             return metrics.calinski harabasz score(X, y pred)
```

```
In [25]: def plot_cluster(k,feature):
    data = df[feature].copy()
    X = data.values.reshape(len(data), 1)
    kmodel = KMeans(n_clusters = k, random_state=0, n_jobs = -1)
    y_pred = kmodel.fit_predict(X)

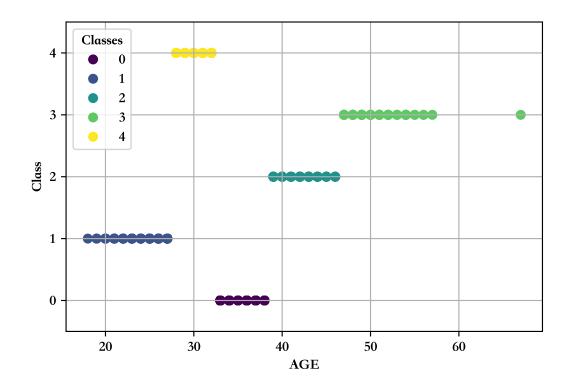
    fig, ax = plt.subplots()
    scatter = ax.scatter(X[:, 0], y_pred,c=y_pred)
    plt.ylim(-0.5, k-0.5)
    plt.grid()
    plt.legend(*scatter.legend_elements(),loc="best", title="Classe")

    plt.xlabel(feature)
    plt.ylabel('Class')
    plt.show()
```

下面是对MONTHLY_INCOME_WHITHOUT_TAX以外的数值属性的2~5的聚类个数进行尝试,并取 calinski_harabasz_score得分最高的k值,还绘制最佳k对应的聚类结果。 最终k除了APPLY_INTEREST_RATE取4,其他都取5,并且都没有跳跃现象,我们认为聚类效果可以接受,接下来就要更改数值成分类结果了。

最终找到的最佳k = 5, 对应的max score = 4882.456915368481

k = 4时, score = 3900.689051645434 k = 5时, score = 4882.456915368481



找 GAGE_TOTLE_PRICE 最合适的k值:

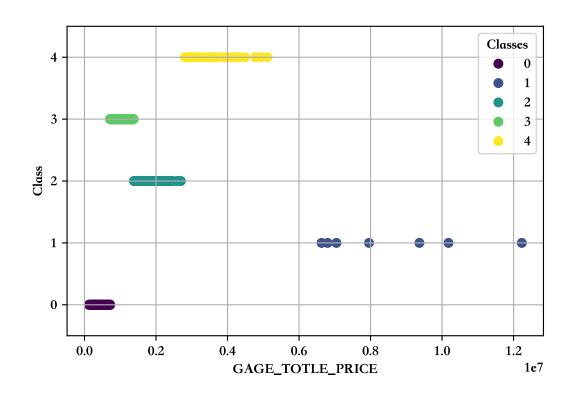
k = 2 ft, score = 1726.9242600311281

k = 3时, score = 2073.715067368992

k = 4 m, score = 3062.7500659269326

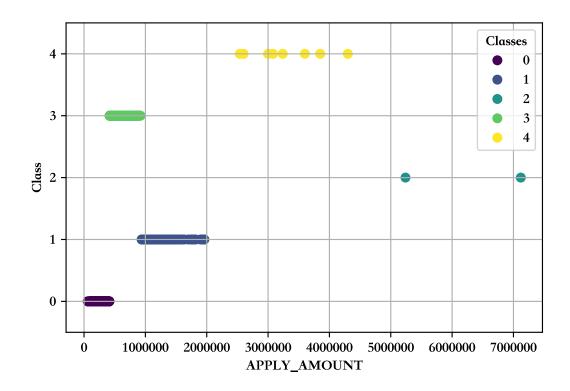
k = 5H, score = 3696.0007568230194

最终找到的最佳k = 5, 对应的max score = 3696.0007568230194



找 APPLY AMOUNT 最合适的k值:

k = 2时, score = 1549.1561106918293k = 3时, score = 2291.9221804399454k = 4时, score = 2779.1180798001533k = 5时, score = 3399.8635602964487最终找到的最佳k = 5, 对应的max score = 3399.8635602964487



找 APPLY_TERM_TIME 最合适的k值:

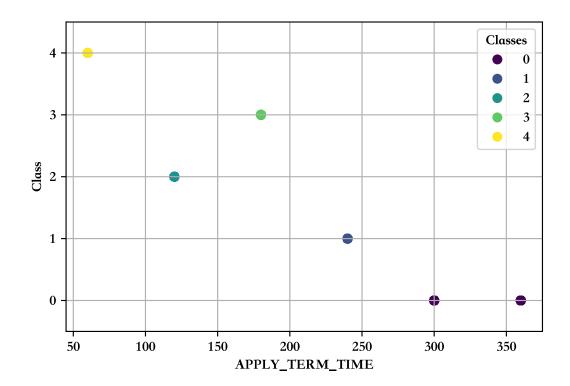
k = 2 ft, score = 2818.150397276408

k = 3时, score = 5292.859344782355

k = 4H, score = 10075.971841927507

k = 5时, score = 22063.041573668695

最终找到的最佳k = 5, 对应的max score = 22063.041573668695



找 APPLY_INTEREST_RATE 最合适的k值:

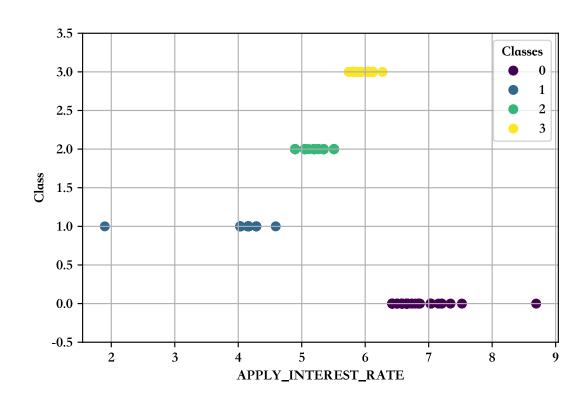
 $k = 2 \text{ ff}, \text{ score} = 5002.090370245115}$

k = 3formula , score = 11344.513738008218

k = 4m, score = 23648.838258102234

k = 5H, score = 22553.694120116303

最终找到的最佳k = 4, 对应的max score = 23648.838258102234



```
In [26]: def predict(k, feature):
             data = df[feature].copy()
             X = data.values.reshape((len(data),1))
             kmodel = KMeans(n clusters = k, random state=0, n jobs = -1)
             y_pred = kmodel.fit predict(X)
             return y pred
In [35]: for i in range(len(num feature list)):
             df[num feature list[i]] = predict(k[i],num feature list[i])
             print(df[num feature list[i]].value counts(normalize=True,ascen
         ding=True))
         3
             0.05028
         2
             0.18980
         1
             0.21813
             0.26558
         4
             0.27620
         Name: AGE, dtype: float64
         1
             0.00496
         4
             0.02266
         2
             0.09278
         3
             0.36048
             0.51912
         Name: GAGE TOTLE PRICE, dtype: float64
         2
             0.00142
             0.00567
         4
         1
             0.05524
         3
             0.32153
             0.61615
         Name: APPLY AMOUNT, dtype: float64
             0.07507
         0
             0.15510
         2
             0.17918
         3
             0.20538
         1
             0.38527
         Name: APPLY TERM TIME, dtype: float64
         3
             0.13456
         0
             0.18201
         2
             0.29391
             0.38952
         Name: APPLY_INTEREST_RATE, dtype: float64
```

GAGE_TOTLE_PRICE、APPLY_AMOUNT存在类取值过小的问题,下面考虑合并,合并目的是最终每个类大于5%,并且不能违反连续的原则。

- GAGE_TOTLE_PRICE中数目小的类1、4、2分别是取值最大、取值第二大、取值第三大的类,所以可以合并
- APPLY_AMOUNT中数目小的类2、4、1分别是取值最大、取值第二大、取值第三大的类,所以可以合并下面执行合并

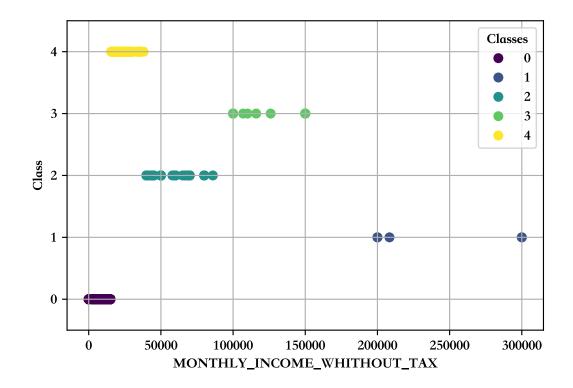
```
In [28]: df["GAGE_TOTLE_PRICE"] = df["GAGE_TOTLE_PRICE"].apply(lambda x: 2 i
    f (x ==1    or x == 4    or x == 2) else x)
    df["APPLY_AMOUNT"] = df["APPLY_AMOUNT"].apply(lambda x: 1 if (x ==2    or x == 4    or x == 1) else x)

In [29]: df["GAGE_TOTLE_PRICE"] = df["GAGE_TOTLE_PRICE"].apply(lambda x: 1 i
    f (x == 3) else x)
    df["APPLY_AMOUNT"] = df["APPLY_AMOUNT"].apply(lambda x: 2 if (x == 3) else x)
```

因为MONTHLY_INCOME_WHITHOUT_TAX异常值和缺失值已经单独分类了,所以其他数值最多只能聚为3 类,下面尝试

```
In [30]: | max score = 0
         best k = 0
         for i in [2,3,4,5]:
             data = df.loc[~df["MONTHLY INCOME WHITHOUT TAX"].isin([-1,-2])]
         ["MONTHLY INCOME WHITHOUT TAX"].copy()
             X = data.values.reshape((len(data), 1))
             kmodel = KMeans(n clusters = i, random state=0)
             y pred = kmodel.fit predict(X)
             score = metrics.calinski harabasz score(X, y pred)
             print(f"k = {i}时, score = {score}")
             if score > max score:
                 max score = score
                 best k = i
         print(f"最终找到的最佳k = {best k}, 对应的max score = {max score}\n")
         fig, ax = plt.subplots()
         scatter = ax.scatter(X[:, 0], y pred,c=y pred)
         plt.ylim(-0.5, best k-0.5)
         plt.grid()
         plt.legend(*scatter.legend elements(),loc="best", title="Classes")
         plt.xlabel("MONTHLY INCOME WHITHOUT TAX")
         plt.ylabel('Class')
         plt.show()
```

```
k = 2时, score = 2230.061826101752k = 3时, score = 2871.7198586676795k = 4时, score = 3346.0210079620356k = 5时, score = 4469.911497105354最终找到的最佳k = 5, 对应的max score = 4469.911497105354
```



```
df["MONTHLY INCOME WHITHOUT TAX"].loc[~df["MONTHLY INCOME WHITHOUT
In [31]:
         TAX''].isin([-1,-2])] = y pred
         df["MONTHLY_INCOME_WHITHOUT_TAX"].value_counts(normalize=True)
In [32]:
Out[32]: 0.00000
                     0.77125
         4.00000
                     0.15793
         2.00000
                     0.04108
         3.00000
                     0.01062
         -2.00000
                     0.00850
         -1.00000
                     0.00708
         1.00000
                     0.00354
         Name: MONTHLY INCOME WHITHOUT TAX, dtype: float64
```

分类之后,我们发现类1、-1、-2、2、3、4都占比低于5%,而类1的odds与类-2、-1、3的都较为接近,且不会造成跳跃,因为类3本身就是和类1相邻。所以我们将类1、-2、-1合并到类3中,见下。

我们发现还有类3和类2不足5%,那么先看类3的odds,发现与类2最接近,我们又想到之前合并进类3的类 1是取值最大的,类3是原本第2大,类2是原本第3大,所以将新类3合并到类2不会造成跳跃,可以合并,见 下

```
In [36]: df["MONTHLY INCOME_WHITHOUT_TAX"].value_counts(normalize=True)
Out[36]: 0.00000
                   0.77125
         4.00000
                   0.15793
         2.00000
                   0.04108
         3.00000
                   0.02975
         Name: MONTHLY INCOME WHITHOUT TAX, dtype: float64
In [37]: check merge odds nearest(df, "MONTHLY INCOME WHITHOUT TAX", 3)
         待合并值 3 的odds = 0.01802451333813987
         取值 0.0 的odds = 0.5150214592274678, 距离是0.4969969458893279
         取值 4.0 的odds = 0.08615384615384615, 距离是0.06812933281570628
         取值 2.0 的odds = 0.023930384336475707, 距离是0.005905870998335838
In [38]: df["MONTHLY INCOME WHITHOUT TAX"] = df["MONTHLY_INCOME_WHITHOUT_TAX
         "].apply(lambda x: 2 if (x == 3) else x)
In [39]: | df["MONTHLY_INCOME_WHITHOUT_TAX"].value_counts(normalize=True)
Out[39]: 0.00000
                   0.77125
         4.00000
                   0.15793
         2.00000
                   0.07082
         Name: MONTHLY INCOME WHITHOUT TAX, dtype: float64
```

最终MONTHLY_INCOME_WHITHOUT_TAX分为3类,为了好看,下面命名为0、1、2

```
In [40]: df["MONTHLY_INCOME_WHITHOUT_TAX"] = df["MONTHLY_INCOME_WHITHOUT_TAX"]
"].apply(lambda x: 1 if (x == 4) else x)
```

Out[42]:

In [42]: df.head()

	ID	Label	AGE	GENDER	MARITAL_STATUS	MONTHLY_INCOME_WHITHOUT_TAX L	1AO.
0	1	1	1	0	0	1.00000	
1	2	1	1	0	1	0.00000	
2	3	1	1	0	1	1.00000	
3	4	0	1	0	2	1.00000	
4	5	0	1	0	2	1.00000	

In [43]: df.to_csv('../data/preprocess.csv',float_format = '%.0f',index=Fals
e)